

# **SME 0520 - Introdução à Estatística**

**Daiane de Souza**

SME/ICMC/USP

Parte III - Março de 2025

# Principais Modelos Probabilísticos

## Modelos Probabilísticos

**Alguns Modelos Discretos:**

- Distribuição Uniforme Discreta;
- Distribuição de Bernoulli;
- Distribuição Binomial;
- Distribuição Geométrica;
- Distribuição Binomial Negativa;
- Distribuição Hipergeométrica;
- Distribuição Poisson.

## Modelos Probabilísticos

**Alguns Modelos Contínuos:**

- Distribuição Uniforme;
- Distribuição Exponencial;
- Distribuição Normal;
- Distribuição t-Student;
- Distribuição Qui-Quadrado;
- Distribuição Gama;
- Distribuição Beta;
- Distribuição Pareto;
- Distribuição Cauchy.

## Recurso Computacional:

- Utilizaremos o *Software R*, disponível para *download* em:  
`https://www.r-project.org/`
- Versão atual: 4.3.1
- O *Software R* tem funções para realizar cálculos de probabilidade, incluindo geração de números aleatórios de uma determinada distribuição especificada.

- As funções têm a seguinte forma geral:

`letranome` (argumentos separados por vírgula)

em que:

`letra`: indica a operação;

`nome`: indica a distribuição de probabilidade.

## Modelos Probabilísticos

## Recurso Computacional

Tabela: Funções do *Software R* para geração de números aleatórios e cálculos de probabilidades.

Letra	Operação	Argumentos necessários
r	Gera números pseudo-aleatórios	Tamanho da amostra, parâmetros da distribuição
p	Calcula a função de probabilidade acumulada	Vetor de quantis, parâmetros da distribuição
q	Calcula o quantil correspondente a uma dada probabilidade	Vetor de probabilidades, parâmetros da distribuição
d	Calcula a densidade de probabilidade	Vetor de quantis, parâmetros da distribuição

## Modelos Probabilísticos

## Recurso Computacional

Tabela: Algumas distribuições de probabilidade no R.

Distribuição	Nome	Argumentos	Default
Poisson	<code>pois</code>	$\lambda$	—
Binomial	<code>binom</code>	$n, p$	—
Binomial negativa	<code>nbinom</code>	$n, p$	—
Geométrica	<code>geom</code>	$p$	—
Hipergeométrica	<code>hyper</code>	$m, n, k$	—
Uniforme	<code>unif</code>	$\min, \max$	0, 1
Exponencial	<code>exp</code>	$\lambda$	—
Normal	<code>norm</code>	$\mu, \sigma$	0, 1
t-Student	<code>t</code>	$df$	—
Beta	<code>beta</code>	$\alpha, \beta$	—
Gama	<code>gamma</code>	$\alpha, \beta$	—



# Alguns Modelos Discretos

## Distribuição Uniforme Discreta

- A variável aleatória assume cada um de seus valores com igual probabilidade.

### Definição:

A variável aleatória discreta  $X$ , assumindo valores  $x_1, x_2, \dots, x_k$  tem **distribuição uniforme** se, e somente se:

$$p_x(x) = P(X = x) = \begin{cases} \frac{1}{k}, & x = x_1, x_2, \dots, x_k \\ 0, & \text{caso contrário} \end{cases}.$$

**Notação:**  $X \sim U_d(k)$ .

**No R:** Não há função pronta.

## Modelos Probabilísticos

## Modelos Discretos

- É fácil verificar que:

$$\mu = E(X) = \sum_{i=1}^k x_i P(X = x_i) = \frac{1}{k} \sum_{i=1}^k x_i$$

e

$$\sigma^2 = \text{Var}(X) = \sum_{i=1}^k (x_i - \mu)^2 P(X = x_i) = \frac{1}{k} \left\{ \sum_{i=1}^k x_i^2 - \frac{\left( \sum_{i=1}^k x_i \right)^2}{k} \right\}.$$

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.1:** Seja  $X$  uma variável aleatória que indica o número de pontos marcados na face superior de um dado quando ele é lançado. Obtenha a f.m.p. de  $X$ , a esperança e variância.

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.1: Solução em R.**

```
> ddu=function(x,a,b) ifelse(x>=a & x<=b & round(x)==x,1/length(a:b),0)
> pdu=function(x,a,b) ifelse(x<a,0,ifelse(x<=b,floor(x)/length(a:b),1))
>
> a=1
> b=6
> x=a:b
> px=ddu(x,a,b)
> px
[1] 0.1666667 0.1666667 0.1666667 0.1666667 0.1666667 0.1666667
>
> E_X=sum(x*px)
> E_X
[1] 3.5
>
> Var_X=sum((x-E_X)^2)*px)
> Var_X
[1] 2.916667
```

## Distribuição de Bernoulli

- Considere uma variável aleatória  $X$  que assume apenas dois valores:

$$\begin{cases} 1, & \text{se ocorrer sucesso} \\ 0, & \text{se ocorrer fracasso} \end{cases}.$$

- Indicaremos por  $p$  a probabilidade de sucesso, isto é,  $P(\text{sucesso}) = P(X = 1) = p$ , sendo  $0 < p < 1$ .

**Definição:**

A variável aleatória discreta  $X$  que assume apenas os valores 0 e 1 tem **distribuição de Bernoulli** se, e somente se:

$$p_X(x) = P(X = x) = \begin{cases} p^x(1 - p)^{1-x}, & x = 0, 1 \\ 0, & \text{caso contrário} \end{cases}.$$

**Notação:**  $X \sim \text{Ber}(p)$ .

**No R:** `dbinom(x, 1, p)` (Número de ensaios é 1).

## Modelos Probabilísticos

## Modelos Discretos

- Vejamos:

- $P(X = 1) = p.$

- $P(X = 0) = 1 - p.$

$x$	0	1
$P(X = x)$	$1-p$	$p$



- Segue-se facilmente que:

$$\mu = E(X) = p$$

e

$$\sigma^2 = \text{Var}(X) = p(1 - p).$$

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.2:** Suponha o lançamento de um dado perfeito e o interesse é ocorrer a face 3. Obtenha a f.m.p. dessa variável aleatória, a esperança e variância.

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.2: Solução em R.**

```
> i=1:6
> x=0:1
> p=1/length(i)
>
> px=dbinom(x,1,p)
> px
[1] 0.8333333 0.1666667
>
> E_X=sum(x*px)
> E_X
[1] 0.1666667
>
> Var_X=sum( ( (x-E_X) ^2) *px)
> Var_X
[1] 0.1388889
```

## Distribuição Binomial

- Considere  $M$  **ensaios de Bernoulli independentes**, todos com a mesma probabilidade de sucesso  $p$ .
- A variável aleatória que conta **o número de sucessos nos  $M$  ensaios de Bernoulli** é denominada **variável aleatória Binomial** com parâmetros  $M$  e  $p$ .

**Exemplo 3.3 (Teórico):** Considere uma linha de produção, em que 3 peças são selecionadas aleatoriamente e são classificadas como defeituosas ( $D$ ) ou não defeituosas ( $N$ ).  $X_1$ ,  $X_2$  e  $X_3$  são variáveis aleatórias que assumem 1 se a peça for não defeituosa e 0 caso contrário. A probabilidade da peça ser não defeituosa é  $p$  e, conseqüentemente, a probabilidade da peça se defeituosa é  $1 - p$ . É de interesse encontrar a distribuição de  $Y = X_1 + X_2 + X_3$ .

**Definição:**

A variável aleatória discreta  $X$ , correspondente ao número de sucessos nos  $M$  ensaios independentes de Bernoulli, tem **distribuição de Binomial** se, e somente se:

$$p_X(x) = P(X = x) = \begin{cases} \binom{M}{x} p^x (1-p)^{M-x}, & x = 0, 1, \dots, M \\ 0, & \text{caso contrário} \end{cases},$$

em que  $\binom{M}{x} = \frac{M!}{x!(M-x)!}$ .

**Notação:**  $X \sim \text{Bin}(M, p)$ .

**No R:** `dbinom(x, M, p)`.

## Modelos Probabilísticos

## Modelos Discretos

- Tem-se que:

$$\mu = E(X) = Mp$$

e

$$\sigma^2 = \text{Var}(X) = Mp(1 - p).$$

**Exemplo 3.4:** Uma rede varejista compra certo tipo de equipamento eletrônico. O fabricante indica que a taxa de equipamentos em perfeito estado é 97%.

- a) Seleciona-se ao acaso 20 destes itens. Qual a probabilidade de que haja pelo menos um item defeituoso nesses 20?
- b) Selecionando-se aleatoriamente 20 itens em cada um de 10 carregamentos, qual a probabilidade de que haja 3 carregamentos com pelo menos um item defeituoso?



## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.4: Solução em R.**

```
> # a)
>
> M=20
> p=0.03
>
> Pi=1-pbinom(0,M,p)
> Pi
[1] 0.4562057
>
> pbinom(0,M,p,lower.tail=F) # outra maneira
[1] 0.4562057
>
>
> # b)
>
> dbinom(3,10,Pi)
[1] 0.1602161
```

**Exercício Proposto 3.1:** Um fabricante adquire certo tipo de componente de um fornecedor. Segundo este fornecedor, a proporção de componentes defeituosos é 2%. O fabricante adquire 10 lotes por mês e cada lote são selecionados 15 componentes para inspeção. Qual a probabilidade de que sejam encontrados 3 lotes com mais de um componente defeituoso?

Resp.: 0, 2570.

## Distribuição Geométrica

- Considere uma sequência de **ensaios de Bernoulli independentes**, todos com a mesma probabilidade de sucesso  $p$  ( $0 < p < 1$ ).
- Seja variável aleatória  $X$  **o número de fracassos anteriores ao primeiro sucesso**.
- Similarmente, a variável aleatória  $X$  pode ser vista como **o número de ensaios que precedem o primeiro sucesso**.

**Definição:**

A variável aleatória discreta  $X$  tem **distribuição de Geométrica** se, e somente se:

$$p_x(x) = P(X = x) = \begin{cases} p(1 - p)^x, & x = 0, 1, \dots, \\ 0, & \text{caso contrário} \end{cases}.$$

**Notação:**  $X \sim \text{Geo}(p)$ .

**No R:** `dgeom(x, p)`.

## Modelos Probabilísticos

## Modelos Discretos

- Tem-se que:

$$\mu = E(X) = \frac{1-p}{p}$$

e

$$\sigma^2 = \text{Var}(X) = \frac{1-p}{p^2}.$$

## Modelos Probabilísticos

## Modelos Discretos

- **Observação:** Uma variável aleatória  $Y$  pode ser vista como o **número de ensaios até a ocorrência do primeiro sucesso**. Neste caso,  $Y$  **tem distribuição Geométrica** com f.m.p. dada por:

$$p_Y(y) = P(Y = y) = \begin{cases} p(1-p)^{y-1}, & y = 1, 2, \dots, \\ 0, & \text{caso contrário} \end{cases}.$$

- Tem-se que  $Y = X + 1$  é uma variável aleatória e  $y = x + 1$  é o seu valor numérico.

## Modelos Probabilísticos

## Modelos Discretos

- Com isso, tem-se que:

$$\mu = E(Y) = E(X) + 1 = \frac{1}{p}$$

e

$$\sigma^2 = \text{Var}(Y) = \text{Var}(X) = \frac{1-p}{p^2}.$$

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.5:** Um pesquisador está realizando experimentos químicos independentes e sabe que a probabilidade de que cada experimento apresente uma reação positiva é 0,3. Qual a probabilidade de que menos de 3 reações negativas ocorram antes da primeira positiva?

**Exemplo 3.5: Solução em R.**

```
> pgeom(2, 0.3)
[1] 0.657
```



## Distribuição Binomial Negativa

- Considere **ensaios de Bernoulli independentes**, todos com a mesma probabilidade de sucesso  $p$  ( $0 < p < 1$ ).
- Definimos a variável aleatória  $X$  como **o número de fracassos anteriores ao  $r$ -ésimo sucesso**.

**Definição:**

A variável aleatória discreta  $X$  tem **distribuição Binomial Negativa** se sua f.m.p. é dada por:

$$p_X(x) = P(X = x) = \begin{cases} \binom{x+r-1}{r-1} p^r (1-p)^x, & x = 0, 1, \dots, \\ 0, & \text{caso contrário} \end{cases}.$$

**Notação:**  $X \sim BN(r, p)$ .

**No R:** `dnbinom(x, r, p)`.

## Modelos Probabilísticos

## Modelos Discretos

- Tem-se que:

$$\mu = E(X) = r \left( \frac{1-p}{p} \right)$$

e

$$\sigma^2 = \text{Var}(X) = r \left( \frac{1-p}{p^2} \right).$$

- **Observações:**

① Note que se  $r = 1$ , temos o **modelo geométrico**;

② 
$$\binom{x+r-1}{r-1} = \binom{x+r-1}{x}.$$

## Modelos Probabilísticos

## Modelos Discretos

- A Binomial Negativa pode ser definida como o **número de ensaios necessários para a obtenção do  $r$ -ésimo sucesso**.
- Tomando  $y = x + r$ , temos a quantidade desejada e seus valores variam de  $r$  em diante.
- Assim, sendo  $Y$  o **número de ensaios necessários para a obtenção de  $r$  sucessos**, temos:

$$p_Y(y) = P(Y = y) = \begin{cases} \binom{y-1}{r-1} p^r (1-p)^{y-r}, & y = r, r+1, \dots, \\ 0, & \text{caso contrário} \end{cases}.$$

## Observação:

- 1 A distribuição Binomial Negativa poder ser caracterizada e termos de soma de variáveis aleatórias seguindo distribuição Geométrica:

Sejam  $X_1, X_2, \dots, X_r$  variáveis aleatórias independentes seguindo distribuição Geométrica com parâmetro  $p$ .

Definindo  $X = \sum_{i=1}^r X_i$ , temos que  $X$  tem distribuição Binomial Negativa com parâmetros  $r$  e  $p$ .

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.6:** Em uma série do campeonato de basquete, o time que ganhar 4 em 7 jogos será o vencedor. Suponha que o time  $A$  tenha probabilidade de 55% de ganhar de  $B$  e que  $A$  e  $B$  se enfrentarão em uma série de 7 jogos. Qual a probabilidade de que  $A$  vença a série em seis jogos?

**Exemplo 3.6: Solução em R.**

```
> dnbinom(2, 4, 0.55)
[1] 0.1853002
```

## Distribuição Hipergeométrica

- Considere um conjunto de  $n$  objetos dos quais  $m$  são do Tipo I e  $n - m$  são do Tipo II.
- Para um sorteio de  $r$  objetos ( $r < n$ ), feito ao acaso e sem reposição, **defina  $X$  como o número de objetos do Tipo I selecionados.**



## Modelos Probabilísticos

## Modelos Discretos

**Definição:**

A variável aleatória discreta  $X$  tem **distribuição Hipergeométrica** se sua f.m.p. é dada por:

$$p_x(x) = P(X = x) = \frac{\binom{m}{x} \binom{n-m}{r-x}}{\binom{n}{r}},$$

em que  $x$  (inteiro) é tal que

$$\max\{0, r - (n - m)\} \leq x \leq \min\{r, m\}.$$

**Notação:**  $X \sim Hgeo(m, n, r)$ .

**No R:** `dhyperv(x, m, n-m, r)`.

## Modelos Probabilísticos

## Modelos Discretos

- **Observação:** Os limites de  $x$  na definição garantem que situações absurdas sejam evitadas. Vejamos:
  - $\max\{0, r - (n - m)\}$ : assegura a contagem adequada nos casos que existem poucos objetos do Tipo II em relação ao número de objetos do Tipo I;
  - $\min\{r, m\}$ : não podemos ter mais do que o número existentes do Tipo I, tampouco mais que o total sorteado.

## Modelos Probabilísticos

## Modelos Discretos

- Temos que:

$$\mu = E(X) = r \frac{m}{n}$$

e

$$\sigma^2 = \text{Var}(X) = \frac{rm(n-m)(n-r)}{n^2(n-1)}.$$

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.7:** Considere que em um lote de 20 peças existam 4 defeituosas. Selecionando-se 5 dessas peças, sem reposição, qual seria a probabilidade de 2 defeituosas terem sido escolhidas?

**Exemplo 3.7: Solução em R.**

```
> dhyper(2, 4, 16, 5)
[1] 0.2167183
```

## Distribuição Poisson

- É largamente empregada quando se deseja contar o número de eventos de certo tipo que ocorrem em um certo período de tempo ou superfície ou volume.
- **Exemplos:**
  - Número de chamadas telefônicas recebidas por uma central telefônica durante 5 minutos;
  - Número de falhas de um computador em um dia de operação;
  - Número de defeitos em peças fabricadas.

## Modelos Probabilísticos

## Modelos Discretos

**Definição:**

A variável aleatória discreta  $X$  tem **distribuição Poisson** com parâmetro  $\lambda$ ,  $\lambda > 0$ , se sua f.m.p. é dada por:

$$p_X(x) = P(X = x) = \begin{cases} \frac{e^{-\lambda} \lambda^x}{x!}, & x = 0, 1, \dots, \\ 0, & \text{caso contrário} \end{cases}.$$

**Notação:**  $X \sim \text{Poi}(\lambda)$ .

**No R:** `dpois(x, λ)`.

## Modelos Probabilísticos

## Modelos Discretos

- Temos que:

$$\mu = E(X) = \lambda$$

e

$$\sigma^2 = \text{Var}(X) = \lambda.$$

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.8:** Uma central telefônica recebe, em média, cinco chamadas por minuto. Supondo que a distribuição Poisson seja adequada nessa situação, obtenha a probabilidade de que a central telefônica receba no máximo duas chamadas durante um intervalo de um minuto.

**Exemplo 3.8: Solução em R.**

```
> ppois(2, 5)
[1] 0.124652
```



## O Processo de Poisson:

- Suponha que  $\mu$  seja a média de ocorrência do evento de interesse em  $t$  unidades de medida (por exemplo, tempo).
- Denotamos por  $\lambda$  a taxa média de ocorrência em uma unidade de medida, com  $\mu = \lambda t$ .
- Podemos escrever a f.m.p. por:

$$p_x(x) = P(X = x) = \begin{cases} \frac{e^{-\lambda t}(\lambda t)^x}{x!}, & x = 0, 1, \dots, \\ 0, & \text{caso contrário} \end{cases}.$$

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.9:** Considerando em **Exemplo 3.8**, qual a probabilidade de que a central telefônica receba no máximo duas chamadas em quatro minutos?

**Exemplo 3.9: Solução em R.**

```
> ppois(2, 5*4)
[1] 4.55515e-07
```

## Resultados Importantes

**Resultado 1:** Se  $X_1, X_2, \dots, X_n$  são variáveis aleatórias independentes e  $X_i \sim Poi(\lambda_i)$ , então  
$$Y = X_1 + X_2 + \dots + X_n \sim Poi(\lambda_1 + \lambda_2 + \dots + \lambda_n).$$

**Resultado 2:** Se  $X \sim Bin(M, p)$ , com  $M$  grande e  $p$  pequeno, pode-se aproximar a distribuição de  $X$  pela Poisson com parâmetro  $\lambda = Mp$ .

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.10:** Em certa instalação industrial, acidentes ocorrem com baixa frequência. Sabe-se que a probabilidade de um acidente ocorrer em um certo dia é de 0,005 e que os acidentes são independentes. Qual a probabilidade de que em um período de 400 dias haja no máximo 3 dias com acidente?

**Exemplo 3.10: Solução em R.**

```
> M=400  
> p=0.005  
> Mu=M*p  
>  
> ppois(3,Mu)  
[1] 0.8571235
```

## Modelos Probabilísticos

## Modelos Discretos

**Exercício Proposto 3.2:** Considerando o **Exemplo 3.10**, calcule a probabilidade considerando a distribuição exata (Binomial) e compare os resultados

Resp.: 0,8575767.

## Distribuição Multinomial

- É uma generalização da distribuição binomial para mais de duas categorias. Enquanto a distribuição binomial lida com dois possíveis resultados (como sucesso/falha), a multinomial trata de experimentos com mais de dois resultados possíveis (categorias). Ela modela a probabilidade de observar um certo número de ocorrências para cada categoria em uma série de experimentos independentes.
- **Exemplo:**
  - Lançamento de um dado: Se você lançar um dado de 6 lados 10 vezes, a probabilidade de observar, por exemplo, três “1”, dois “2”, um “3”, zero “4”, dois “5” e dois “6” pode ser modelada por uma distribuição multinomial.

**Definição:**

A distribuição binomial pode ser generalizada considerando a repartição do espaço amostral em  $k$  eventos  $A_1, A_2, \dots, A_k$ , mutuamente exclusivos. Considerem-se  $n$  repetições do experimento. Seja  $p_i = P(A_i)$  e suponha-se que  $p_i$  permaneça constante durante

todas as repetições. Evidentemente, teremos  $\sum_{i=1}^k p_i = 1$ . Definam-se as variáveis aleatórias  $X_1, X_2, \dots, X_k$  como segue:  $X_i$  é o número de vezes que  $A_i$  ocorre nas  $n$  repetições do experimento,  $i = 1, \dots, k$ .

Os  $X_i$  não são variáveis aleatórias independentes, porque  $\sum_{i=1}^k X_i = n$ .

## Modelos Probabilísticos

## Modelos Discretos

**Teorema:**

Se  $X_i, i = 1, 2, \dots, k$ , forem definidas como anteriormente, teremos

$$P(X_1 = n_1, X_2 = n_2, \dots, X_k = n_k) = \frac{n!}{n_1! n_2! \dots n_k!} p_1^{n_1} \dots p_k^{n_k},$$

em que  $\sum_{i=1}^k n_i = n$ .

- Para  $k$  igual a 2 a expressão anterior se torna a distribuição binomial;
- Se  $X_1, \dots, X_k$  tem distribuição multinomial,

$$E(X_i) = np_i \quad \text{e} \quad V(X_i) = np_i(1 - p_i)$$

**No R:** `dmultinom(x, p)`.



**Exemplo 3.11:** Qual é a probabilidade de se lançar um dado de 6 lados 9 vezes, se encontrar 3 lados 1, 2 lados 6, e os demais lados 1 vez?

**Exemplo 3.11: Solução em R.**

```
> X=c(3,2,1,1,1,1)
> p=c(1/6,1/6,1/6,1/6,1/6,1/6)
>
> dmultinom(X,prob=p)
[1] 0.003000686
```

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.12:** Uma fábrica de lâmpadas coloridas produz 50% de lâmpadas verdes, 20% de lâmpadas azuis e 30% de lâmpadas amarelas. Qual é a probabilidade de em 6 lâmpadas 2 sejam verdes, 3 azuis e 1 amarela? Qual é a probabilidade de em 8 lâmpadas 4 sejam verdes, 2 azuis e 2 amarelas?

**Exemplo 3.12: Solução em R.**

```
> X=c(2, 3, 1)
> p=c(1/2, 1/5, 3/10)
>
> dmultinom(X, prob=p)
[1] 0.036
```

# Outros Exemplos

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.13:** Um site contém 3 servidores idênticos. Somente um deles é usado para operar o site, os outros dois são sobressalentes que podem ser ativados no caso de o sistema principal falhar. A probabilidade de falha é 0,0005. Supondo que cada solicitação represente uma tentativa independente, qual será o número médio de solicitações até a falha dos 3 servidores? Qual a probabilidade de todos os 3 servidores falharem em 5 solicitações?

**Exemplo 3.14:** Contaminação é um problema de fabricação de discos ópticos. O número de partículas de contaminação que ocorrem em um disco tem distribuição de probabilidade discreta e o número médio de partículas por  $\text{cm}^2$  de superfície é 0,1. A área da superfície do disco em estudo é  $100 \text{ cm}^2$ . Encontre a probabilidade de que 12 partículas sejam encontradas em um disco.

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.15:** Uma batelada de peças contém 100 peças de um fornecedor local de tubos e 200 peças de um fornecedor de um fornecedor de um estado vizinho. Se 4 peças forem selecionadas, ao acaso e sem reposição, qual será a probabilidade de que elas sejam todas provenientes do fornecedor local? Qual é a probabilidade de duas ou mais peças na amostra serem provenientes do fornecedor local? Qual é a probabilidade de no mínimo uma peça na amostra ser proveniente do fornecedor local?

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.16:** Em uma fábrica, dados mostram que em 3 semanas típicas os números médios de acidentes são 2,5 na 1<sup>ª</sup> semana, 2 na 2<sup>ª</sup> semana e 1,5 na 3<sup>ª</sup> semana. Suponha que o número de acidentes por semana segue uma distribuição de Poisson. Qual a probabilidade de que ocorram 4 acidentes em 3 semanas?

## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.17:** Suponha-se que o custo de realização de um experimento seja R\$1.000,00. Se o experimento falhar, ocorrerá um custo adicional de R\$300,00 em virtude de serem necessárias algumas alterações antes que a próxima tentativa seja executada. Se a probabilidade de sucesso em uma tentativa qualquer for 0,20, se as provas foram independentes, e se os experimentos continuarem até que o primeiro resultado frutuoso seja alcançado, qual será o custo esperado do procedimento completo?



## Modelos Probabilísticos

## Modelos Discretos

**Exemplo 3.18:** Em determinada localidade, a probabilidade da ocorrência de uma tormenta em algum dia durante o verão (nos meses de dezembro e janeiro) é igual a  $0,1$ . Admitindo-se independência de um dia para outro, qual é a probabilidade da ocorrência da primeira tormenta da estação de verão no dia 3 de janeiro?

# Alguns Modelos Contínuos

## Distribuição Uniforme

### Definição:

Uma variável aleatória contínua  $X$  tem **distribuição Uniforme** no intervalo  $[\alpha; \beta]$ , com  $\alpha, \beta \in \mathbb{R}$ , se sua f.d.p. é dada por:

$$f_X(x) = \begin{cases} \frac{1}{\beta - \alpha}, & \alpha \leq x \leq \beta \\ 0, & \text{caso contrário} \end{cases}.$$


**Notação:**  $X \sim U(\alpha, \beta)$ .

**No R:** `punif(x, alpha, beta)`.

## Modelos Probabilísticos

## Modelos Contínuos

- Uma ilustração gráfica da f.d.p. de  $X$  é:



## Modelos Probabilísticos

## Modelos Contínuos

- A f.d.a. da distribuição uniforme é facilmente encontrada:

$$\begin{aligned} F_x(x) = P(X \leq x) &= \int_{-\infty}^x f_x(t) dt \\ &= \int_{\alpha}^x \frac{1}{\beta - \alpha} dt = \frac{1}{\beta - \alpha} t \Big|_{\alpha}^x = \frac{x - \alpha}{\beta - \alpha}. \end{aligned}$$

Então,

$$F_x(x) = \begin{cases} 0, & x < \alpha \\ \frac{x - \alpha}{\beta - \alpha}, & \alpha \leq x \leq \beta \\ 1, & x \geq \beta \end{cases}.$$

## Modelos Probabilísticos

## Modelos Contínuos

- Temos que:

$$\mu = E(X) = \frac{\alpha + \beta}{2}$$

e

$$\sigma^2 = \text{Var}(X) = \frac{(\beta - \alpha)^2}{12}.$$

## Modelos Probabilísticos

## Modelos Contínuos

**Exemplo 3.19:** Seja  $X$  uma variável aleatória com distribuição uniforme,  $U\left(-\frac{1}{2}; \frac{1}{2}\right)$ . Calcule:

a)  $F_X(x)$ .

b)  $P\left(-\frac{1}{4} < X \leq \frac{1}{4}\right)$ .

c)  $E(X)$  e  $Var(X)$ .

## Modelos Probabilísticos

## Modelos Contínuos

**Exemplo 3.19: Solução em R.**

```
> # b)
>
> a=-1/2; b=1/2
>
> punif(1/4,a,b)-punif(-1/4,a,b)
[1] 0.5
>
> # c)
>
> E_X=(a+b)/2
> E_X
[1] 0
>
> Var_X=((b-a)^2)/12
> Var_X
[1] 0.08333333
```



## Modelos Probabilísticos

## Modelos Contínuos

**Exemplo 3.19: Solução em R (continuação).**

```
> # c) outra maneira:
>
> fdp=function(x,a=-1/2,b=1/2) ifelse(x>=a & x<=b,1/(b-a),0)
> E_X= function(x) x*fdp(x)
> E_X2=function(x) (x^2)*fdp(x)
>
> integrate(E_X,-1/2,1/2)$value
[1] 0
> integrate(E_X2,-1/2,1/2)$value-((integrate(E_X,-1/2,1/2)$value)^2)
[1] 0.08333333
```

## Distribuição Exponencial

### Definição:

Uma variável aleatória contínua  $X$  tem **distribuição Exponencial** com parâmetro  $\lambda$ ,  $\lambda > 0$ , se sua f.d.p. é dada por:

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & \text{caso contrário} \end{cases}.$$


**Notação:**  $X \sim \text{Exp}(\lambda)$ .

**No R:** `pexp(x, λ)`.

## Modelos Probabilísticos

## Modelos Contínuos

- Uma ilustração gráfica da f.d.p. de  $X$  é:



## Modelos Probabilísticos

## Modelos Contínuos

- A f.d.a. da distribuição exponencial é dada por:

$$\begin{aligned}F_x(x) = P(X \leq x) &= \int_{-\infty}^x f_x(t) dt \\&= \int_0^x \lambda e^{-\lambda t} dt = -e^{-\lambda t} \Big|_0^x = 1 - e^{-\lambda x}.\end{aligned}$$

Então,

$$F_x(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}.$$

## Modelos Probabilísticos

## Modelos Contínuos

- Temos que:

$$\mu = E(X) = \frac{1}{\lambda}$$

e

$$\sigma^2 = \text{Var}(X) = \frac{1}{\lambda^2}.$$

**Propriedade:**

a) Se  $X \sim \text{Exp}(\lambda)$ , então  $P(X > a + b | X > b) = P(X > a)$ .

Esta propriedade é conhecida por “falta de memória” e é a única distribuição contínua com esta propriedade.

## Modelos Probabilísticos

## Modelos Contínuos

- Outra parametrização para a distribuição exponencial:

$$f_x(x) = \begin{cases} \frac{1}{\alpha} e^{-x/\alpha}, & x \geq 0 \\ 0, & \text{caso contrário} \end{cases}.$$

- Utilizando esta parametrização, temos que:

$$\mu = E(X) = \alpha$$

e

$$\sigma^2 = \text{Var}(X) = \alpha^2.$$

## Modelos Probabilísticos

## Modelos Contínuos

**Exemplo 3.20:** Seja  $X$  o tempo de vida de um fusível que tem distribuição exponencial com média de 100 horas. Qual a probabilidade de um fusível durar mais de 150 horas?

**Exemplo 3.20: Solução em R.**

```
> lambda=1/100
>
> 1-pexp(150,lambda)
[1] 0.2231302
>
> # outra maneira
> pexp(150,lambda,lower=F)
[1] 0.2231302
```



## Modelos Probabilísticos

## Modelos Contínuos

**Exercício Proposto 3.3:** O tempo  $X$  antes do primeiro reparo em uma certa máquina tem distribuição exponencial com parâmetro  $\lambda = \frac{1}{4}$  reparo/mês. Qual a probabilidade de que um reparo seja necessário após 6 meses de uso? E antes de um ano de uso?

Resp.: 0, 22313 e 0, 95021.

## Distribuição Normal

- É o mais importante dos modelos probabilísticos.
- A **distribuição Normal** é também conhecida como **distribuição Gaussiana**.
- Sua representação gráfica é conhecida pela curva em forma de sino.

## Modelos Probabilísticos

## Modelos Contínuos

**Definição:**

Uma variável aleatória contínua  $X$  tem **distribuição Normal** com parâmetros  $\mu$  (média) e  $\sigma^2$  (variância) se sua f.d.p. é dada por:

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}, \quad -\infty < x < \infty,$$

em que  $-\infty < \mu < \infty$  ( $\mu \in \mathbb{R}$ ) e  $\sigma^2 > 0$ .


**Notação:**  $X \sim N(\mu; \sigma^2)$ .

**No R:** `pnorm(x, μ, σ)`.

## Modelos Probabilísticos

## Modelos Contínuos

- Uma ilustração gráfica da sua f.d.p. é:



## Modelos Probabilísticos

## Modelos Contínuos

- Temos que:

$$\mu = E(X)$$

e

$$\sigma^2 = \text{Var}(X),$$

ou seja, a distribuição é parametrizada pela sua média e pela sua variância.

**Propriedades:**

a) A distribuição é simétrica em relação á média. Isto é,

$$f_X(\mu - x) = f_X(\mu + x), \forall x \in \mathbb{R}.$$


b) Como a área total sob a curva é igual a 1, à esquerda e à direita de  $\mu$  a área é igual a 0,5.

c) Tem-se as seguintes probabilidades:

$$\begin{aligned}P(\mu - \sigma \leq X \leq \mu + \sigma) &= 0,6896 \\P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) &= 0,9546 \\P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) &= 0,9973.\end{aligned}$$

## Modelos Probabilísticos

## Modelos Contínuos



## Modelos Probabilísticos

## Modelos Contínuos

- A f.d.a. da distribuição normal é dada por:

$$\begin{aligned}F_x(x) = P(X \leq x) &= \int_{-\infty}^x f_x(t) dt \\&= \int_{-\infty}^x \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(t-\mu)^2} dt,\end{aligned}$$

cuja integral não tem solução analítica.

**Pergunta:** Como calcular probabilidade?

**Resposta:** Cálculo de probabilidades com auxílio de tabela.



**Definição:**

Se  $X \sim N(\mu; \sigma^2)$ , então a variável aleatória  $Z$  definida por

$$Z = \frac{X - E(X)}{\sqrt{\text{Var}(X)}} = \frac{X - \mu}{\sigma},$$

terá distribuição normal com média 0 e variância 1,  $Z \sim N(0; 1)$ , conhecida como **distribuição normal-padrão ou reduzida**.

## Cálculo de Probabilidades:

- A seguir os cálculos de probabilidades a partir de exemplos.

**Exemplo 3.21 (Uso da tabela normal-padrão):** Seja  $Z \sim N(0; 1)$ , calcule:

a)  $P(0 \leq Z \leq 1,65)$ .

b)  $P(Z \leq 0,5)$ .

c)  $P(Z \leq -1,57)$ .

d)  $P(-0,65 \leq Z \leq 0,65)$ .

e)  $P(0,80 \leq Z \leq 1,40)$ .

f)  $P(0 \leq Z \leq z) = 0,4753$ .

g)  $P(Z \leq z) = 0,05$ .

## Modelos Probabilísticos

## Modelos Contínuos

**Exemplo 3.21: Solução em R.**

```
> # a)
> pnorm(1.65) - pnorm(0)
[1] 0.4505285
>
> # b)
> pnorm(0.5)
[1] 0.6914625
>
> # c)
> pnorm(-1.57)
[1] 0.05820756
>
> # d)
> pnorm(0.65) - pnorm(-0.65)
[1] 0.4843078
```

## Modelos Probabilísticos

## Modelos Contínuos

**Exemplo 3.21: Solução em R (continuação).**

```
> # e)
> pnorm(1.40) - pnorm(0.80)
[1] 0.1310987
>
> # f)
> qnorm(0.5+0.4753)
[1] 1.965123
>
> # g)
> qnorm(0.05)
[1] -1.644854
```

## Modelos Probabilísticos

## Modelos Contínuos

**Exemplo 3.22:** Seja  $X \sim N(90; 100)$ . Determine:

- a)  $P(80 \leq X \leq 100)$ .
- b)  $P(X \leq 90)$ .
- c)  $P(60 \leq X \leq 75)$ .

## Modelos Probabilísticos

## Modelos Contínuos

**Exemplo 3.22: Solução em R.**

```
> # a)
> pnorm(100, 90, 10) - pnorm(80, 90, 10)
[1] 0.6826895
>
> # b)
> 1 - pnorm(90, 90, 10)
[1] 0.5
>
> # outra maneira
> pnorm(90, 90, 10, lower=F)
[1] 0.5
>
> # c)
> pnorm(75, 90, 10) - pnorm(60, 90, 10)
[1] 0.0654573
```

## Modelos Probabilísticos

## Modelos Contínuos

**Exemplo 3.23:** Suponha que as medidas da corrente em um pedaço de fio sigam a distribuição normal, com uma média de 10 miliamperes e uma variância de 4.

- a) Qual é a probabilidade de a medida exceder 13 miliamperes?
- b) Qual é a probabilidade de a medida estar entre 9 e 11 miliamperes?
- c) Determine o valor para o qual a probabilidade de uma medida da corrente estar abaixo desse valor seja 0,98.

**Exercício Proposto 3.4:** Seja  $X \sim N(50; 10^2)$ . Determine:

- a)  $P(30 \leq X \leq 70)$ .
- b)  $P(|X - 50| < 10)$ .
- c)  $P(\mu - a \leq X \leq \mu + a) = 0,90$ .
- d)  $P(k \leq X \leq 70) = 0,8185$ .
- e)  $P(k \leq X \leq 75) = 0,3031$ .

**Resp.:** a) 0,9544; b) 0,6826; c)  $a = ?$ ; d)  $k = ?$ ; e)  $k = ?$ .



## Modelos Probabilísticos

## Modelos Contínuos

**Observação:** Seja  $Z \sim N(0; 1)$ . Considere a probabilidade:

$$P(a \leq Z \leq b) = 0,95.$$

Quais os valores de  $a$  e  $b$ ?

Vejamos:

- a)  $P(-1,96 \leq Z \leq 1,96) = 0,95$ ;
- b)  $P(-1,93 \leq Z \leq 2,01) = 0,951$ ;
- c)  $P(-2,55 \leq Z \leq 1,70) = 0,95$ ;
- d)  $P(-2,33 \leq Z \leq 1,75) = 0,95$ .

## Resultado Importante

**Resultado 1 (Aproximação da Binomial pela Normal):** Suponha que  $X \sim \text{Bin}(M, p)$ . Já sabemos que  $E(X) = Mp$  e  $\text{Var}(X) = Mp(1 - p)$ . Para calcular as probabilidades

- ★  $P(a \leq X \leq b)$  ou  $P(a < X \leq b)$  ou  $P(a \leq X < b)$  ou  $P(a < X < b)$
- ★  $P(X \geq a)$  ou  $P(X > a)$
- ★  $P(X \leq b)$  ou  $P(X < b)$ ,

é razoável considerar a distribuição normal com média e variância iguais às da distribuição Binomial.

## Modelos Probabilísticos

## Resultado Importante

- Em outras palavras, tem-se a aproximação da distribuição de probabilidade de  $X$  pela distribuição de uma variável aleatória  $Y$ , sendo  $Y \sim N(\mu; \sigma^2)$ , em que  $\mu = Mp$  e  $\sigma^2 = Mp(1 - p)$ .
- Portanto, como exemplo,

$$P(X \geq a) \approx P(Y \geq a),$$

com  $Y \sim N(Mp; Mp(1 - p))$

**Observação:**

- O cálculo de probabilidade aproximado é feito da forma usual para a distribuição normal.
- A aproximação da distribuição binomial pela normal é boa quando  $Mp(1 - p) \geq 3$ .

## Modelos Probabilísticos

## Resultado Importante

**Exemplo 3.24:** Uma prova é constituída de 20 testes com 4 alternativas cada. Um aluno não estudou a matéria e vai respondê-las ao acaso. Qual a probabilidade de acertar 50% ou mais das questões?

### Exemplo 3.23: Solução em R.

```
> M=20
> p=1/4
>
> (Mu=M*p)
[1] 5
> (Var=M*p*(1-p))
[1] 3.75
>
> 1-pnorm(10,Mu,sqrt(Var))
[1] 0.004911637
>
> # outra maneira
> pnorm(10,Mu,sqrt(Var),lower=F)
[1] 0.004911637
```

**Exercício Proposto 3.5:** Considere as informações do **Exemplo 3.23**. Calcule a probabilidade exata (baseada na distribuição Binomial) e avalie o erro cometido ao calcular com a aproximação pela distribuição normal.

Resp.: ?